

Lec 2. Stationary 아닌걸 어떻게 stationary로?!

대체적으로 평균을 중심으로 왔다갔다

trend 존재 = 평균이 시점에 따라 변함
= weakly stationary 조건 위반

De-trend in time series.

time series trend 제거

1. In practice, the observed time series are not stationary in many reasons.
2. Particular, often there is a trend in series.
3. We introduce two ways to remove trend in time series. One is the classical regression analysis, and the other is taking difference.

1. Regression analysis in time series 회귀분석으로 트렌드 제거

1. Generalized least square

- Observations $\{(x_i, y_i)\}_{i=1}^n$ are from the model

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon,$$

where

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} \quad \text{and} \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix}$$

↓ ↓ ↓ 설명 변수의 관측값
design matrix

and ϵ ($p \times 1$) vector has multivariate normal distribution with mean 0 and variance Σ ($p \times p$), matrix.

- The minimum variance unbiased estimator of β the solution to the weighted least square problem

$$(\mathbf{Y} - \mathbf{X}\beta)^T \Sigma^{-1} (\mathbf{Y} - \mathbf{X}\beta).$$

- The solution is

$$\hat{\beta} = (\underbrace{\mathbf{X}^T \Sigma^{-1} \mathbf{X}}_{\mathbf{I}})^{-1} \underbrace{\mathbf{X}^T \Sigma^{-1} \mathbf{Y}}_{\mathbf{I}}.$$

무엇이 아냐
↙ $\hat{\mathbf{Y}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$
부분과 동일

$$1 \quad \Sigma = \begin{pmatrix} \sigma^2 & & 0 \\ & \ddots & \\ 0 & & \sigma^2 \end{pmatrix} : \text{공분산 행렬}$$

오의 공분산 행렬: $\begin{pmatrix} \sigma^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_n^2 \end{pmatrix} = \sigma^2 I$ 꼴

$$* Y = X\beta + \varepsilon$$

design matrix, 각 col: 설명변수 관측값 (주로 첫번째 col은 1 (절편))

* 시계열에선 오가 정상시계열 모형이 되게끔 하는 것이 목표. - WN제외 오끼리 상관관계 생김 (= cov $\neq 0$)
 \Rightarrow 일반화 최소제곱법 사용: weight (\leftarrow 오의 공분산을 역행렬로 곱해줌; GLS: 가중치 준 거리)

$$* X = (X_1, \dots, X_p), \quad b = \begin{pmatrix} b_1 \\ \vdots \\ b_p \end{pmatrix}, \quad Xb = b_1 X_1 + \dots + b_p X_p \quad (\text{Linear combination}), \quad X_j = \begin{pmatrix} x_{1j} \\ \vdots \\ x_{nj} \end{pmatrix}$$

$$\{Xb : b \in \mathbb{R}^p\} = \text{sp}(X_1, \dots, X_p)$$

$$\text{최소제곱법} \quad \sum_{i=1}^n \{Y_i - (b_1 x_{1i} + \dots + b_p x_{pi})\}^2 = (Y - Xb)^T (Y - Xb) = \|Y - Xb\|^2$$

\hookrightarrow Y벡터와 제일 가까운 span 안에 원소 찾기

$$\therefore \hat{Y} = X(X^T X)^{-1} X^T Y$$

* 거리

방향이나 가중치 다르게

W : positive definite, $\|v\|_W^2 = v^T W v \geq 0$ ($v=0$ 일때만 0, p.d 의 정의에 의해)

$$(Y - X\beta)^T \Sigma^{-1} (Y - X\beta).$$

· If $\Sigma^{-1} = W$ 면 형태 동일, n 차원 공간에서의 거리 (Σ : 회전)

· 식을 최소화: $Y \sim Xb$ 거리에서 제일 가까운 점: 수직 \rightarrow 내적 = 0 ($\langle v_1, v_2 \rangle_W = v_1^T W v_2 = 0$)

$$\hat{\beta} = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} Y$$

X 의 크기들의 합

X 와 Y 의 내적들

X 와 Y 의 내적들 (각각 Σ 의 내적 모양으로 바꿔)

\rightarrow $\frac{\text{내적}}{\text{거리}}$: projection


* 가중최소제곱법 (GLS의 형태 중)

$$\sum (Y_i - (b_1 x_{1i} + \dots + b_p x_{pi}))^2 \frac{1}{\sigma_x^2} \quad : \text{오끼리 독립 but 오 분산 다다름} \rightarrow \text{오 큰거} \rightarrow \text{weight} \downarrow$$

\rightarrow 오 작을거 \rightarrow weight \uparrow


$$\text{이 때의 } \Sigma = \begin{pmatrix} \sigma^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{pmatrix}$$

- Global warming (estimate linear trend)




$$x_t = \beta_0 + \beta_1 t + w_t$$

일차식보다 이차식이 더 적합할수도!




$r = Y - \hat{Y}$ 을 나타낸 그래프

→ 증가하는 트렌드 서열




- Cardiovascular mortality series (estimate periodic trend)



내려가는 패턴 + 주기성 둘다 반영


$$x_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 t^3 + \alpha_1 \cos(2\pi t / \underline{52}) + \alpha_2 \sin(2\pi t / 52) + w_t$$

1년(52주)마다
1 사이클 되도록!



residual-mortality

잔차그래프 - 평균을 중심으로 왔다갔다.



$$Y_t = m(t) + X_t \quad \{X_t\} : \text{stationary}$$

1) $m(t)$ 모형화 $\rightarrow \hat{m}(t)$ 찾기

$$(X\text{형식}) \quad \underline{\hat{X}_t} = Y - \hat{m}(t) \approx \underline{X_t} \quad \text{비슷한 성질 가짐!}$$

- **Routine for generalized least square**
 - run OLS (IID errors).
 - estimate covariance matrix of error terms, Σ , using residuals.
 - run GLS with the estimate covariance matrix estimate.
 - iterate the above steps.

Difference and back-shift operator

Definition 0.1. *We define the backshift operator by*

$$Bx_t = x_{t-1}$$

and extend it to powers $B^2x_t = B(Bx_t) = Bx_{t-1} = x_{t-2}$.

- Consider the first difference is

$$\Delta x_t = x_t - x_{t-1} = (1 - B)x_t$$

$$\Delta^2 x_t = (1 - B)^2 x_t = (1 - 2B + B^2)x_t$$

- We can eliminate *linear* trend with Δ
- We can eliminate *2nd order* trend with Δ^2
- We can eliminate *d-th order* trend with Δ^d

< Difference and back-shift operator >

① back shift operator : 한 시점 전으로 옮김.

$$Bx_t = x_{t-1}$$

$$B^n x_t = x_{t-n}$$

② Differencing

$$\Delta x_t = x_t - x_{t-1} \quad : \text{현재값과 전 값의 차이}$$

$$\Delta_k^n \leftarrow \text{몇번했나}$$

$$\Delta_k \leftarrow \text{몇칸전이나}$$

$$= (1-B)x_t$$

$$\Delta^2 x_t = (1-B)^2 x_t$$

$$\Delta(\Delta x_t) = \Delta(x_t - x_{t-1}) = \Delta x_t - \Delta x_{t-1} = (x_t - x_{t-1}) - (x_{t-1} - x_{t-2}) \\ = x_t - 2x_{t-1} + x_{t-2} = (1 - 2B + B^2)x_t = (1-B)^2 x_t$$

$$\Delta^n x_t = (1-B)^n x_t$$

* Δ : 차수 줄이는데 사용 (time trend 제거) / 메리는 없으나 한 번 할때마다 하나의 데이터 손실

$$\text{ex) } Y_t = \beta_0 + \beta_1 t + X_t$$

$$\Delta Y_t = \beta_0 + \beta_1 t + X_t - (\beta_0 + \beta_1 (t-1) + X_{t-1}) = \beta_1 + X_t - X_{t-1} \quad (\text{time trend (t) 사라짐})$$

ex) random walk

$$X_t = X_{t-1} + \varepsilon_t \rightarrow \text{평행일정, 분산변함} \rightarrow \text{stationary } X$$

$$X_t - X_{t-1} = \varepsilon_t \rightarrow \varepsilon_t \text{가 stationary} \text{면 } X_t - X_{t-1} \text{도 stationary} \rightarrow \text{그래서 차분법 자주 쓰임!}$$

참) fitting - smoothing - Time series 대략적인 형질속에 확인
- 가중